Projet Walmart

Prévision des recettes hebdomadaires des magasins

Contexte

Lien Github

- Afin de mieux comprendre les fluctuations de leur chiffre d’affaire, Walmart souhaite modéliser leur chiffre d’affaire à partir de données économiques variées.

- Cela leur permettrait de réaliser des campagnes marketing plus pertinentes.

Méthodologie du projet

Nettoyage des données

- **Isolation** de la variable cible et suppression des lignes sans cible.
- **Création** de colonnes explicitant le contenu de la colonne date (year, month, day, day of week).
- **Suppression** des valeurs aberrantes zones à fort potentiel solaire selon les données historiques et prévisionnelles

Entrainement d'une baseline

- **Entraînement** d'un modèle de régression linéaire pour servir de référence.
- **Enregistrement** des entraînements sur un serveur mlflow
- **Identifier** les zones à fort potentiel solaire selon les données historiques et prévisionnelles

Réduction du surapprentissage

- **Tests** de modèles de régularisation (ridge et lasso).
- **Optimisation** de l'hyperparamètre alpha des modèles testés via Optuna.
- **Enregistrement** des zones à fort potentiel solaire selon les données historiques et prévisionnelles

Tracking via mlflow

Lien MLFlow

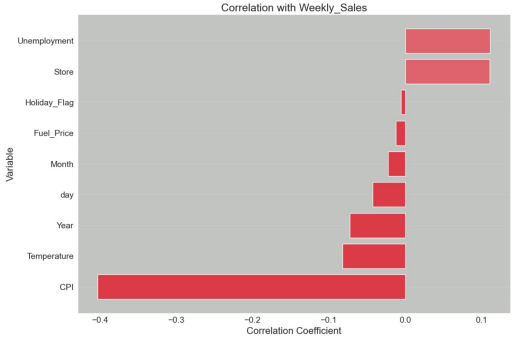

Pics de consommation par jour et heure – France

Run Name	Created	Dataset	Duration	Source	Models	Adjusted_R2	MAE	MSE	RMSE	best_mse	best_rmse	alpha
graphLog_attempt	6 days ago	-	6.5min	Walmart...	Lasso	-	-	-	-	1530473694...	123712.3152...	0.960225735...
debonair-sheep-...	6 days ago	-	28.6s	Walmart...	Lasso	0.918777961...	90930.65706...	1531413424...	123750.2898...	-	-	-
welcoming-owl-...	6 days ago	-	30.3s	Walmart...	Lasso	0.918660941...	91416.86298...	1533619792...	123839.4037...	-	-	-
welcoming-shre...	6 days ago	-	30.4s	Walmart...	Lasso	0.918661309...	91415.14475...	1533612854...	123839.1236...	-	-	-
spiffy-bat-613	6 days ago	-	28.7s	Walmart...	Lasso	0.918660965...	91416.74963...	1533619334...	123839.3852...	-	-	-
languid-fawn-771	6 days ago	-	28.8s	Walmart...	Lasso	0.918660945...	91416.84301...	1533619711...	123839.4005...	-	-	-
thundering-robi...	6 days ago	-	29.4s	Walmart...	Lasso	0.918809162...	90515.23017...	1530825137...	123726.5184...	-	-	-
serious-boar-177	6 days ago	-	31.6s	Walmart...	Lasso	0.918661197...	91415.66931...	1533614972...	123839.2091...	-	-	-
magnificent-was...	6 days ago	-	28.8s	Walmart...	Lasso	0.918661027...	91416.46371...	1533618179...	123839.3386...	-	-	-
efficient-koi-295	6 days ago	-	31.1s	Walmart...	Lasso	0.918660941...	91416.86278...	1533619791...	123839.4037...	-	-	-
likeable-stoat-546	6 days ago	-	45.3s	Walmart...	Lasso	0.918827802...	90337.18707...	1530473694...	123712.3152...	-	-	-
graphLog_attempt	7 days ago	-	6.4min	Walmart...	Ridge	-	-	-	-	2044216437...	142976.0971...	0.003145695...
delicate-bass-483	7 days ago	-	28.2s	Walmart...	Ridge	0.200462771...	303018.2664...	1507499769...	388265.3435...	-	-	-
respected-fowl-...	7 days ago	-	30.9s	Walmart...	Ridge	0.687413658...	160127.8240...	5893707275...	242769.5877...	-	-	-
angry-deer-939	7 days ago	-	28.2s	Walmart...	Ridge	0.891580272...	111244.1052...	2044216437...	142976.0971...	-	-	-
gifted-moth-734	7 days ago	-	28.0s	Walmart...	Ridge	0.731024197...	153228.1124...	5071445649...	225198.7044...	-	-	-
marvelous-donk...	7 days ago	-	28.7s	Walmart...	Ridge	0.704517931...	157506.8820...	5571212123...	236034.1526...	-	-	-
intelligent-fowl-...	7 days ago	-	28.7s	Walmart...	Ridge	0.686761272...	160225.8311...	5906007778...	243022.7927...	-	-	-
trusting-ape-257	7 days ago	-	29.1s	Walmart...	Ridge	0.344652608...	252911.7229...	1235634822...	351515.9772...	-	-	-
classy-bear-114	7 days ago	-	36.0s	Walmart...	Ridge	0.582690424...	167643.4555...	7868227597...	280503.6113...	-	-	-
powerful-boar-8...	7 days ago	-	36.0s	Walmart...	Ridge	0.641086213...	158455.3527...	6767195215...	260138.3327...	-	-	-
resilient-whale-7...	7 days ago	-	49.4s	Walmart...	Ridge	0.703613606...	157648.0289...	5588262862...	236395.0689...	-	-	-

heure

heure

Comparaison des modèles

Lasso vs Ridge

Lasso : rmse 123 712

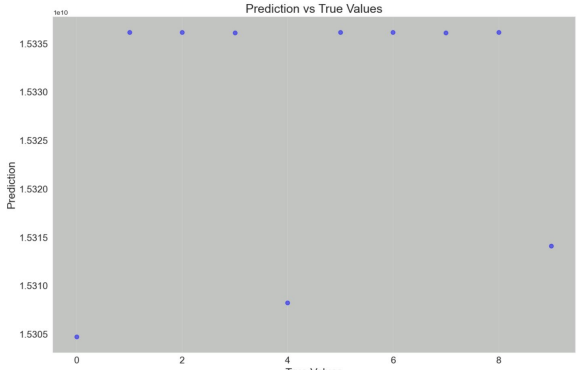

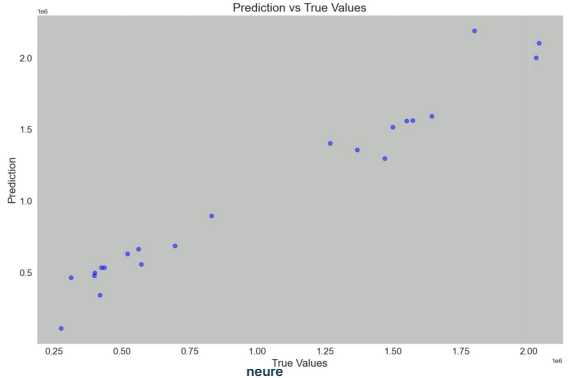

neure

Ridge : rmse 142 976

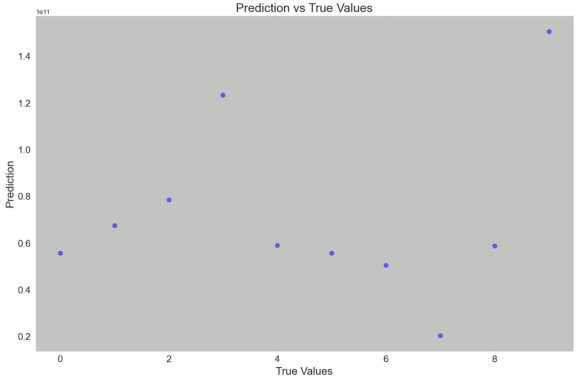

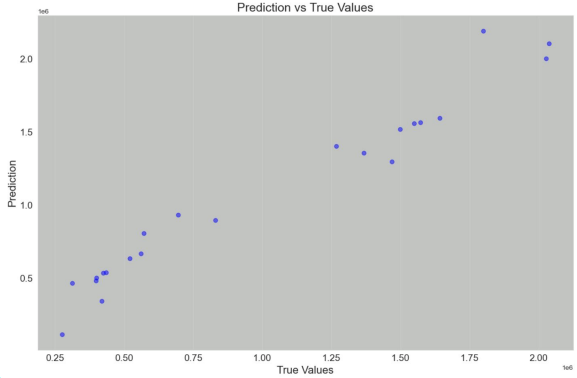

Conclusion

- **Régression linéaire :** très mauvaise, loin de la cible
- **Lasso vs Ridge** :
  - Différence marginale (20k delta sur une RMSE de 120-140k)
  - Différence concentrée sur 2 points
  - RMSE d'environ 10% de la valeur prédite

Amélioration du modèle

What's next ?

- **Changement de modèle de production automatique** via un changement d'alias des modèles.
- **Étude de la pertinence** de la RMSE vs MAE.

Jedha

Des questions ?

Ressources projet en annexes